

Validation croisée par LLM-juge des configurations expérimentales

Projet : ns4kge - Knowledge Graph d'articles sur le Negative Sampling pour les KGE

Objet : vérification automatique indépendante des 6 567 configurations numériques extraites

Juge : GPT-5.6 Terra (OpenAI) - indépendant du modèle de peuplement (Claude)

Périmètre : 55 articles · 6 567 configurations · vérification 100 % automatique

1. Résumé exécutif

Un **second LLM, indépendant** du pipeline d'extraction, vérifie chaque configuration extraite (croisement *dataset x metric x KGE model x NS method* -> *valeur*) directement contre les **tableaux bruts** de l'article. Sur les 6 567 configurations :

Métrique	Résultat (micro, global)
① La valeur existe dans les tableaux	99.9 % (6 562 / 6 567)
② La combinaison est correctement associée à la valeur	99.5 % (6 533 / 6 567) - <i>brut</i>
② après adjudication manuelle des écarts	99.92 % (6 562 / 6 567)
③ Canaris (sanity anti-tamponnage) attrapés	54 / 55 articles

Le chiffre brut de 99.5 % signale **34 configurations**. Leur adjudication montre que **5 seulement sont de vraies imprécisions d'extraction** ; les **29 autres sont des faux positifs du juge**, dus à ses limites de localisation dans des tableaux à structure complexe (lignes labellisées par méthode, rowspan imbriqués). La précision réelle du pipeline sur l'association *combinaison* -> *valeur* est donc de **99.92 %**.

Un score inférieur à 100 % est ici un **gage de crédibilité** : le validateur détecte réellement des écarts (il ne tamponne pas), et le canari indépendant confirme article par article qu'il sait attraper une erreur injectée.

2. Contexte et objectif

Le pipeline extrait, pour chaque article, un ensemble de **configurations expérimentales**. Chaque configuration associe cinq descripteurs à une valeur numérique :

```
{ Dataset, Task, Metric, KGEModel, NSMethod } -> result
```

Une première validation (par entité : datasets, metrics, KGE models, NS methods...) contrôle la **justesse des entités** extraites. Elle ne dit rien sur la **cohérence des tuples ni des valeurs numériques**. La présente validation comble ce trou : elle vérifie que chaque valeur numérique est **réelle** et **correctement associée** à sa combinaison de descripteurs, telle qu'imprimée dans les tableaux de résultats du papier.

Le rappel n'est volontairement pas mesuré : le pipeline n'extrait pas toutes les lignes de tous les tableaux, par conception. On mesure la **précision** de ce qui a été extrait.

3. Méthodologie

3.1 Principe : un juge indépendant

Le peuplement du graphe a été réalisé avec **Claude**. Pour éviter qu'un modèle valide ses propres angles morts, le vérificateur est d'une **famille différente** : **GPT-5.6 Terra** (OpenAI). Le juge ne reçoit **que** les tableaux et les configurations - jamais le raisonnement du pipeline.

3.2 Choix du modèle

- **Indépendance** : extraction = Claude -> juge = GPT (non Claude).
- **GPT-4o** n'est plus disponible via l'API (retiré le 16/02/2026) ; la gamme actuelle est la famille GPT-5.6 (Luna / Terra / Sol).
- **Luna** (le tier économique) produisait des **faux « tuple absent »** sur les entêtes multi-niveaux. Le passage à **Terra** (tier équilibré) les a supprimés. Coût total du run complet : de l'ordre de **1 \$**.

3.3 Entrées

- **Source** = les **JSON** *_merged.json (jamais les TTL). La normalisation des pourcentages vers [0,1] a lieu **au passage JSON->TTL** (déterministe, hors périmètre) ; le JSON conserve la valeur **verbatim** du tableau, ce qui permet une comparaison directe.
- **Tableaux** = **extraits bruts** des articles (blocs <table> HTML + légendes), non réécrits : chaque tableau ayant une forme différente, tout « nettoyage » automatique risquerait de perdre une colonne. On préfère laisser le juge lire la forme d'origine.

3.4 Représentation minimaliste (déterministe)

Les configurations sont transmises au juge sous forme compacte : la **Task** (constante par tableau) est factorisée en tête de section, le reste par ligne, avec un identifiant = index d'origine dans le JSON (pour le remapping) :

```
== task: Link Prediction ==
id|dataset|metric|model|ns|val
0|WN18RR|MRR|Rotate|Unknown|0.476
1|WN18RR|MRR|MuRP|Unknown|0.477
...
```

Cette transformation JSON->forme minimaliste est **100 % déterministe** (recopie de chaînes, aucun LLM). Le surcoût de tokens est faible : préambule fixe (~600 tokens) + le bloc de configurations. Le plus gros article (cake, 320 configs) tient sous **~9 000 tokens** en entrée.

3.5 Les deux vérifications et la définition de « correct »

Une cellule de tableau de résultats n'encode que **trois coordonnées** (dataset, metric, model) + **une valeur** : il n'existe généralement ni colonne NS ni colonne Task. Le juge effectue donc, par configuration, **deux contrôles** :

- **(A) La valeur existe** - le nombre apparaît-il quelque part dans les tableaux ?
(distingue une valeur hallucinée d'une valeur réelle)
- **(B) La combinaison est correcte** - le nombre est-il à la **bonne cellule**, c'est-à-dire la cellule (dataset, metric, model) existe et vaut cette valeur, avec la NS cohérente ?

Une configuration est **correcte** **(B)** (et alors (A) l'est nécessairement). Une configuration peut avoir **(A) vrai mais (B) faux** : la valeur est réelle mais rattachée à la **mauvaise combinaison** (bon nombre, mauvais dataset par exemple).

NSMethod / Task :

- NSMethod = "Unknown" est **toujours accepté** (le tableau n'a pas de colonne NS) ; une NS *spécifique* n'est fautive que si le tableau la contredit clairement.
- Task est **ignorée** ici (elle est contrôlée par la validation d'entités).

3.6 Comparaison numérique

Tolérance de **forme uniquement**, jamais de rééchelonnage :

26.96 == "26.96%" (on retire le signe %), 0.43 == 0.430 (zéros/arrondis), mais

0.43 != 43 (pas de x100 - cette normalisation appartient au TTL, hors périmètre).

3.7 Règles de lecture des tableaux (durcies)

Le juge est explicitement instruit des schémas « pièges » rencontrés :

- **en-têtes multi-niveaux** (colspan) : mapper chaque cellule à (dataset = groupe de tête, metric = sous-colonne) ;
- **abréviations / coquilles** : H@1 == Hits@1, WN8RR == WN18RR, MuRp == MuRP ;
- **ligne « méthode proposée »** : souvent labellisée Proposed / Ours / l'acronyme du papier, **pas** par le nom du modèle -> utiliser la NS pour choisir la bonne ligne ;
- **rowspan imbriqué** : un modèle chapeautant plusieurs sous-lignes (une par NS) -> apparier (model, ns) à la bonne sous-ligne.

3.8 Sortie et rapport

Le juge ne renvoie que les **anomalies** (report^{by}exception) : [{"id":i, "exists":bool}], et [] si tout est correct. La sortie **scale avec le nombre d'erreurs**, pas avec le nombre de configurations. Un script **déterministe** transforme ensuite cette réponse en rapports lisibles (.md, .json, _SUMMARY.md).

3.9 Canari anti-tamponnage (sanity par article)

Pour prouver, **article par article**, que le juge discrimine (et ne valide pas tout aveuglément), une **fausse configuration déterministe** est injectée dans chaque appel, indiscernable d'une vraie ligne (id séquentiel, valeur plausible). Il s'agit d'un ****swap de dataset : une vraie valeur du tableau placée à la mauvaise cellule**** (repli sur valeurs 0.7 si aucun swap possible). Si le juge la signale, il a prouvé qu'il sait localiser correctement. Le canari est retiré des statistiques réelles.

4. Résultats globaux

Métrique	Valeur	Détail
Configurations vérifiées	6 567	55 articles
① La valeur existe	99.9 %	6 562 / 6 567
② Combinaison correcte (brut)	99.5 %	6 533 / 6 567
② Combinaison correcte (adjudgé)	99.92 %	6 562 / 6 567
③ Canaris attrapés	54 / 55	seul eans échoue (voir §6)

Observation clé. Les 5 seules configurations à valeur `existe = faux` sont **exactement** les 5 vraies imprécisions d'extraction. Toutes les autres configurations signalées (29) ont

valeur existe = vrai : leur valeur est réelle, seul le juge n'a pas su la localiser. La métrique ① sépare donc, à elle seule, le **vrai signal** (imprécision réelle) du ****bruit du juge**** (faux positif de localisation).

5. Adjudication des 34 configurations signalées

Chaque écart signalé par le juge a été vérifié **à la main** contre le tableau source.

Catégorie	Nb	Nature
N - vraies imprécisions d'extraction	5	valeur absente des tableaux
M - limites de localisation du juge (faux positifs)	29	valeur réelle, correctement placée, mal localisée par le juge
Total signalé	34	

5.1 N - Vraies imprécisions d'extraction (5)

Article	Configs	Cas
localcognitive	#57, #61, #77, #81 (4)	result = None - valeur manquante (Hits@1 / Hits@3 non extraits)
noigan	#78 (1)	FB15K■237 / MRR / Attention = 0.436 - la valeur n'apparaît dans aucun tableau

Ces 5 cas sont de véritables lacunes : soit une valeur nulle, soit une valeur qui ne se retrouve pas dans les tableaux de résultats. Ce sont les seuls écarts imputables au pipeline.

5.2 M - Faux positifs du juge (29)

Dans les 29 cas, la valeur extraite est **réelle et correctement placée** ; le juge n'a pas su la relier à la bonne ligne à cause de la structure du tableau. Trois schémas :

(a) Ligne labellisée par méthode NS, pas par modèle - gns (3)

Table FB13 : lignes UNS, PTNS, GNS. Le pipeline a correctement associé
 ns=Uniform -> UNS = 0.5182, ns=Pseudo Typed -> PTNS = 0.8972, ns=Good -> GNS = 0.9013
 (la proposée, en gras). Le juge cherchait KGEModél = KG■BERT (absent du tableau, c'est le modèle de base implicite) et n'a pas relié.

(b) Ligne « méthode » sans modèle de base (KBGAN) - hasa (4) + noigan (16) = 20

Le tableau contient une ligne KBGAN [4] (KBGAN est une méthode de NS concurrente), avec ses valeurs (ex. MRR 0.277, Hits@10 0.458). Le pipeline a correctement extrait ces valeurs sous ns=KBGAN avec un KGEModél **vide** (la ligne ne mentionne pas de modèle de base). Le juge, exigeant un modèle pour localiser la cellule, n'a pas pu confirmer - alors que la valeur est exacte.

(c) Rowspan imbriqué - ccs (6)

Table à <td rowspan="4">TransR</td> chapeautant quatre sous■lignes (une par méthode : Bernoulli, KBGAN, NSCaching, ...). Les six valeurs TransR / NSCaching (3639, 0.201, 0.4822, 181, 0.2751, 0.4773) **existent toutes** dans la sous■ligne correspondante ; le juge a mal navigué la structure imbriquée.

Note méthodologique : le durcissement du prompt (schémas *proposed■row* et *rowspan*) a déjà ramené l'article cans de 66.7 % à 100 % (18 faux positifs corrigés). Les schémas (a),

(b), (c) résiduels illustrent les limites de localisation d'un LLM sur les tableaux scientifiques les plus tordus.

6. Le cas eans - canari non attrapé (1 / 55)

Sur eans, le canari injecté n'a **pas** été signalé par le juge (0/1), y compris après une seconde exécution. La sanity **échoue** pour cet article : son score de 100 % (aucune anomalie sur ses 180 configurations réelles) **ne peut pas être confirmé** par le mécanisme de canari. Aucune vraie erreur n'y a été trouvée, mais l'article est signalé comme ****« à vérifier »**** par transparence - le canari a rempli son rôle de détecteur de non■fiabilité.

7. Limites et menaces à la validité

- **Taux d'erreur propre du juge.** Le juge n'est pas parfait : 29 faux positifs de localisation, et 1 canari raté sur 55. La validation croisée fournit donc une ****borne inférieure automatique**** (99.5 %) ; l'adjudication manuelle établit la valeur réelle (99.92 %). La métrique ① (« valeur existe ») offre un garde■fou robuste et automatique.
 - **Frontière avec la validation d'entités.** Certaines informations (méthode NS décrite dans le *corps* de l'article mais absente des *tableaux*, ex. `randomcorrupt`) sont hors de portée d'une validation table■only ; elles relèvent de la validation d'entités qui lit le corps. Les deux validations sont **complémentaires**.
 - **Rappel non mesuré**, par conception.
-

8. Conclusion

La validation croisée par LLM■juge indépendant établit, **de façon entièrement automatique**, que les 6 567 configurations extraites sont correctes à **99.5 %** (borne brute) sur l'association *combinaison* -> *valeur*, et à **99.92 %** après adjudication des écarts. Les valeurs numériques sont réelles à **99.9 %**. Le mécanisme de canari confirme, sur 54 des 55 articles, que le juge discrimine effectivement.

Les rares écarts se répartissent en **5 vraies imprécisions d'extraction** (valeurs manquantes/absentes) et **29 faux positifs du juge** liés à la structure de certains tableaux (lignes labellisées par méthode, rowspan imbriqués). L'ensemble constitue une preuve de qualité **crédible et traçable** : un résultat non parfait, obtenu par un vérificateur indépendant, auto■contrôlé par canari, et intégralement adjugeable.